

# Homework 2

Link a progetto Github: [https://github.com/giorgiomelch/Ingegneria-dei-Dati\\_h2](https://github.com/giorgiomelch/Ingegneria-dei-Dati_h2).

I file da indicizzare sono stati raccolti da Giallo Zafferano, salvati in formato .txt. Il filename è il nome della ricetta, mentre il contenuto del file è la presentazione del piatto.

Esempio:



- Filename: "Spaghetti alla carbonara"
- Contenuto: "Volete preparare la vera carbonara cremosa, come da tradizione romana? Bastano pochi ingredienti per preparare questo primo piatto: guanciale croccante, tuorli, Pecorino Romano e pepe nero. Il segreto per ottenere la crema perfetta è mantecare fuori dal fuoco con un po' di acqua di cottura. Nessuna panna, solo gusto autentico! In questa ricetta vi sveliamo passo dopo passo come ottenere la carbonara originale, cremosa e irresistibile, da preparare con gli spaghetti o con il formato di pasta che preferite. Nella sua semplicità e nella qualità degli ingredienti, la pasta alla carbonara è una delle ricette italiane più amate. Come la cacio e pepe, l'amatriciana o la pasta alla gricia, racchiude in pochi gesti tutta la forza della cucina romana."

## Analyzer scelti e motivazioni:

- **PerFieldAnalyzerWrapper**: è stato utilizzato per assegnare un analizzatore diverso a ciascun campo del documento indicizzato. In questo modo è possibile trattare in maniera distinta il contenuto testuale e il nome del file.
- **SimpleAnalyzer** per il campo "**filename**": il nomi dei file sono stringhe brevi e semplici. Consente una tokenizzazione semplice, che suddivide il testo in token

alfanumerici e converte tutto in minuscolo, senza applicare rimozione di stopwords o tecniche linguistiche.

- **ItalianAnalyzer** per il campo "**content**": gestisce stemming, stopwords italiane e tokenizzazione, adatto per il dominio di ricette italiane permettendo di collegare varianti morfologiche di uno stesso termine (es "cottura", "cotture", "cuocere").

## **Numero di file indicizzati e tempi:**

Sono stati indicizzati **51 file** con parole medie per il titolo pari a 3,68 , per contenuto 145.35.

**Tempo di indicizzazione: 723 ms.**

## **Query usate per testare il sistema**

nome pasta	contenuto buono +carne
nome alla	contenuto zafferano NOT pasta
contenuto zafferano	contenuto -pasta +carne
contenuto carne -secondo	contenuto buon*
contenuto pesce +primo	contenuto +pasta +guanciaie -tuorlo - uovo